

恶意 Multi-Agent 攻击框架：78 篇文献查重与研究边界

面向社交媒体推荐、动态检测和干预环境，区分已经覆盖的攻击能力与仍可研究的组织韧性边界。

结论先行

检索截止：2026-07-26。 本轮纳入 78 篇研究。你的方向仍然能做，但不能再把‘协同’、‘自适应攻击’或‘动态角色’单独当作创新。

最稳的主线是：平台干预所诱发的恶意 LLM-Agent 组织重构与韧性。当推荐、检测、限流和封禁造成关键成员损失时，坏 Agent 团队自动识别岗位空缺、选择接班者、迁移任务和记忆、重连通信拓扑，并恢复传播。

本轮没有发现一篇同时覆盖持久社交身份、推荐曝光、持续检测/封禁、多恶意 LLM Agent 分工、成员损失后的职位接替与拓扑重构，并用恢复时间和组织存活评测韧性的论文。‘未发现’是检索结论，不是绝对首创证明。

纳入文献的证据层级

Source: paper_matrix.csv 的层级计数

Table: paper_matrix

证据层级	论文数	含义
直接社交攻击	17	直接研究恶意、欺骗或影响型社交 Agent
强相邻研究	32	LLM-MAS 攻击、安全、角色和拓扑方法
平台与仿真	20	推荐、舆论、图和治理基础设施
早期方法先驱	9	2023 年及以前的 MARL、bot 和归因方法

2023 年分界应该怎样使用

2023 年及以前的工作通常不是成熟的 LLM-Agent 社会团队，因此不直接封死系统级创新；但它们仍会封死宽泛的机制主张。显式收益、目标价值、检测—影响权衡、MARL 推荐攻击、固定异质角色和 Shapley 信用分配都已有早期先例。正确表述是：早期方法提供组件，本项目研究这些组件进入持久、生成式、可对话的恶意 LLM 团队后，在动态平台干预下产生的新组织行为。

最接近本课题的工作

Source: 论文原文与摘要的人工编码

工作	已经做到	不能再宽泛声称	仍可区分的边界
RogueAgent (2025)	中心/去中心组织、共享记忆、推荐、干预适应	首次协同、首次 leader/member、首次封禁适应	成员损失后的岗位接替与组织恢复未显式建模
MAFF-Bench (2025/ICLR 2026)	公开/私密通信、多阶段诈骗、目标分析、角色涌现	首次多阶段欺骗、首次涌现领导	未评测干预触发的角色生命周期和继任
STAR attack (2026)	多个恶意Agent协同并根据同伙反馈动态切换攻击策略	首次自适应协同攻击	切换话术而非组织岗位；无推荐和封禁
MASTER (2025)	角色/拓扑感知并动态分配攻击任务	首次动态攻击任务分配、首次角色感知攻击	任务型MAS；无持久社交身份和成员损失恢复
GroupGuard (2026)	虚假共识、定向压制、群体合谋和动态图防御	首次群体合谋策略	非开放社交传播；无账号经济和接班
MAStrike (2026)	Shapley引导的脆弱联盟与角色感知协同红队	首次Shapley攻击归因	层级工作流MAS；无持续社交组织
GraphMind (2026)	LLM bot构造人类化全局关系图，削弱文本与GNN检测	首次图感知隐蔽	没有干预驱动的组织重建
AgentAttack (2026)	LLM Agent自主规划多策略推荐投毒	首次LLM自适应推荐攻击	非公开社交传播中的团队继任

已经被做过的点

- RogueAgent 已有中心/去中心协同、共享记忆和干预适应；MAFF-Bench 已有公开/私密协同、多阶段欺骗和角色涌现。
- Language Evolution 和 STAR 已让恶意 Agent 根据监管或盟友反馈动态改变攻击话术。
- MASTER、Dynamic Role Assignment、MasRouter 和动态拓扑研究已覆盖角色/任务/通信的动态配置。
- BotSim、Advanced Social Botnets、GraphMind 和 RoBCtrl 已覆盖行为、内容、目标、群体状态和图结构隐蔽。
- AgentAttack 与 MultiAttack 已覆盖 LLM 或 MARL 推荐攻击。
- MAGIC、OpenEvoShield 和 MAStrike 分别覆盖攻防共演化、持续防御和 Shapley 引导的角色感知攻击。

研究方向决策表

Source: 文献重合度与项目可行性的综合判断

Table: research_decisions

候选点	建议	原因
干预触发的组织重构与传播恢复	主创新	本轮未找到同时满足平台、封禁、成员损失、接替、重连和恢复评测的直接工作
推荐—检测—组织闭环	框架贡献	单个组件均已有工作，组合可支撑主问题但不宜独立宣称首次
动态角色分配	实现机制	一般动态角色、路由和角色感知攻击已有论文
显式团队收益函数	基础接口	收益、预算、目标价值、检测权衡均有先例
反事实/Shapley成员贡献	解释与度量	成熟MARL方法且MAStrike已用于攻击红队
Twibot-22真实验证	证据增强	适合网络/persona校准、检测器和解释案例，不是机制创新

建议的研究问题

在推荐驱动且持续检测/干预的社交平台中，具备干预感知角色重构能力的恶意 LLM-Agent 团队，是否比固定角色、预设 leader 和无角色团队具有更高传播韧性？增益来自职位接替、通信重连还是目标重分配，又会付出多少检测风险与成本？

建议定义恢复时间、功能连续性、继任成功率、角色 churn、组织存活曲线以及韧性—隐蔽 Pareto 前沿。收益函数只是模块接口；干预导致的组织响应及其因果效果才是研究对象。

最小实验矩阵

Source: 由研究问题推导的实验设计

Table: experiment_matrix

维度	条件	回答的问题
组织	独立 / 固定中心化 / 去中心 / 固定专门角色 / 干预感知动态重构	证明新组织机制超过交大原基线
冲击	随机移除 / 封leader / 限流桥接者 / 降权内容者 / 连续冲击	区分一般适应与关键岗位恢复
消融	仅换目标 / 换角色 / +记忆迁移 / +拓扑重连	定位效果来自哪一步
规模	10 / 72 / 100 / 500 / 1000 / 可选5000; 30-50 timestep	兼顾已有数据、机制调试和规模效应
指标	传播、渗透、检测、成本、恢复时间、继任率、功能连续性、组织存活	同时衡量攻击效果、隐蔽和韧性

可用于论文的安全表述

据我们截至 2026 年 7 月的检索，现有工作分别研究了 LLM 社交 bot 协同、检测反馈下的话术适应、角色感知攻击任务分配、动态通信拓扑、推荐攻击和持续防御，但尚未系统研究平台干预造成关键成员损失时，恶意 LLM-Agent 社群如何进行职位接替、任务与记忆迁移、通信重构并恢复传播。我们据此提出干预感知的恶意组织重构机制和组织韧性评测协议，并在推荐—检测—干预闭环中比较其与独立、固定中心化、去中心化和固定角色攻击的差异。

核心论文入口

[RogueAgent](#) · [MAFF-Bench](#) · [TrendSim](#) · [Language Evolution](#) · [STAR](#) · [MASTER](#) · [GroupGuard](#) · [MAStrike](#) · [GraphMind](#) · [AgentAttack](#)

完整的 78 篇逐条矩阵见同目录 paper_matrix.csv；Markdown 版报告包含方法、实验和写作建议。